卷积神经网络

（convolutional neural networks，CNN）

为什么需要？对于图象识别，多层感知机无法利用图像中的已知结构，而图像的像素数量很大，仅用多层感知机训练效率极低且效果不好。

-> 卷积神经网络（CNN）是机器学习**利用自然图像中一些已知结构**的创造性方法。

从全连接层到卷积

在处理"从图片中找到某模式"的任务中，我们有两个原则：

1. **平移不变性**：同一个模式出现在图像哪里，都应该能被识别，和其出现的位置无关
2. **局部性**：神经网络前面几层主要关注局部邻域，而不是一开始就建模远距离关系

下面，从数学上的输入到输出的公式的变化，来实现以上两个原则

符号语言：

- X：输入图像
- H：隐藏表示 / 输出特征图
- $H[i,j]$：输出中位置 (i,j) 的那个值
- $X[k,l]$ 或 $X[i+a,j+b]$：输入图像里的某个像素
- W,V：权重
- U,u：偏置

首先，对于多层感知机（MLP），由输入到输出的公式如下

$$H[i,j]=U[i,j]+\sum_a\sum_b V[i,j,a,b]\,X[i+a,j+b]$$

其中，a，b 可以理解为对于固定的 i，j 在二维图像上像素坐标的偏移量。

这个式子表示：每计算一个输出里的数据点 $H[i,j]$，都要对输入的所有像素点的值进行加权求和，不同的位置 (i,j) 权重和偏置还不一样。这就导致参数量爆炸。

1. **运用"平移不变性"**，既然模式出现在哪里都是同一种模式，理应平等对待，所以权重不再依赖 (i,j)，偏置也不再依赖 (i,j)。故公式优化为

$$H[i,j]=u+\sum_a\sum_b V[a,b]\,X[i+a,j+b]$$

也就是说，无论算哪个地方的输出，都用同一套"检测模版" $V[a,b]$ 和偏置 u（参数共享）

2. **运用"局部性"**，在算 (i,j) 的时候不管离 (i,j) 太远的点（也就是 a，b 过大的点）所以求和变成领域求和，公式优化为

$$H[i,j]=u+\sum_{a=-\Delta}^{\Delta}\sum_{b=-\Delta}^{\Delta}V[a,b]\,X[i+a,j+b]$$

至此，一个全连接层就被优化为了卷积层

直观理解：原来，想要算输出中的某点，需要将输入中全部的点都加权求和，再加上一个偏置，这里每个输入点都有自己的权重和偏置，参数量极大

现在，想要算输出中的某点，只需要取该点附近很小一块部分来计算，用一套固定的模式来计算（权重只和偏移量 a，b 有关，和目前在算哪个点的输出无关），而且偏置也统一为常数。

卷积神经网络是包含卷积层的一类特殊的神经网络。

上式中的 V 被称为**卷积核**（convolution kernel）或者**滤波器**（filter），是可学习参数

Eg 来直观地看一下参数/计算次数减少了多少

一张图片，100×100

若使用多层感知机，其参数量为：

- 权重：$100^4=10^8$
- 偏置：$100^2=10^4$ 总参数为 100010000
- 计算次数（算加法的次数）：约 10^8

若使用卷积网络，规定 $\Delta=5$，其参数量为：

- 权重：$11\times11=121$
- 偏置：1 总参数为 122
- 计算次数（算加法的次数）：约 10^6

总结：第一步约束（平移不变性）减少参数量

第二步约束（局部性）减小计算量

卷积：两个二维张量的卷积公式

$$(f * g)(i,j) = \sum_a \sum_b f(a,b)\, g(i-a, j-b)$$

彩色图片：对于现实的彩色图片，通常是 3 维的

例如 $1024 \times 1024 \times 3$ 表示横 1024 像素 $\times$ 竖 1024 像素 $\times$ 3 通道（RGB）颜色强度

故公式改为

$$[H]_{i,j,d} = \sum_{a=-\Delta}^{\Delta} \sum_{b=-\Delta}^{\Delta} \sum_c [V]_{a,b,c,d}\, [X]_{i+a,j+b,c}$$

注意第三个通道不受局部性约束

图像卷积

卷积层通过一个小卷积核 V 在图像上滑动，对局部区域做乘加运算，从而提取边缘等局部特征；并且卷积核的参数可以通过训练自动学习得到。

严格来讲这种计算应该叫互相关，但是影响不大。

一个简单的例子：卷积核 V 大小 2×2，在输入 3×3 上移动遍历乘加得到输出（此处略去偏置）

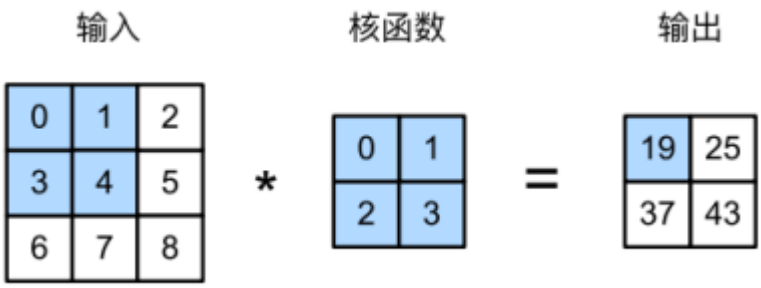

给定输入和对应的输出进行训练，模型学的是核函数的元素值（也就是权重）和偏置

卷积层也被称为**特征映射**：直观理解，一个卷积核在输入上遍历得到输出的过程，就是在寻找原图中的某种"规则"或者特征，来映射到输出中，且保留相对空间关系。

感受野：对于任意一层的某个元素 x，更前的层里面前向传播中可能对 x 的值产生影响的所有区域的集合就是感受野。例如上图中输出"19"的感受野就是输入左上角 2×2 区域

填充和步幅

问题：如果像上面那样卷积，如果卷积核的大小不是 1×1，必然导致输出缩水。如果卷积层数很多，图像缩水会很严重。

解决方法：

1. **填充（padding）**：在原始图像周围填一圈 0（相当于扩展，由于本身不存在所以填 0）如下图所示

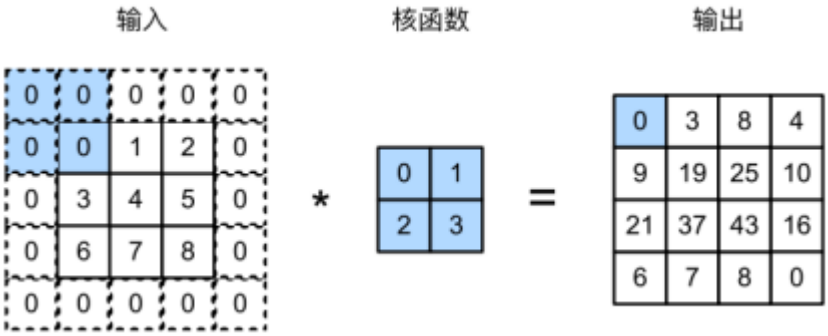

填充后，输出会比填充前要大，并且其中心部分保持和未填充时一样

好处：首先是避免尺寸缩小过快。其次，让**边缘的信息**相较之前更被重视（例如上图中原输入右上角的 2，填充前只有一次参与到求和中，而中心的 5 参与了 4 次。填充后大家都是 4 次，重视程度相当）

2. **步幅**：决定卷积核每次在输入上移动几格。例如上面的所有情况都是横向=纵向=1

例如上图如果将步幅改为横向=纵向=2，则输出仅为 2×2

当然横向步幅和纵向步幅可以不一样。

例如上图如果将步幅改为横向=1，纵向=3，则输出为 2×4（2 行 4 列）

好处：减小计算量，加速图像缩小等。

两者共同作用，有效**控制每一层图像的大小如何变化**，来实现特定目的。

多输入多输出通道

第一小节最后，我们提到真实的彩色图像其实有三"层"数据（RGB）。这一节我们将上面的单通道拓展为多通道

1. **多输入单输出**：最直观的例子就是彩色图像。此时，输入，输出和卷积核都是多层的。计算时，各层**独立计算**，只在最后将**相应的结果相加**得到一层的输出（单输出）

下面这个是 2 层的例子

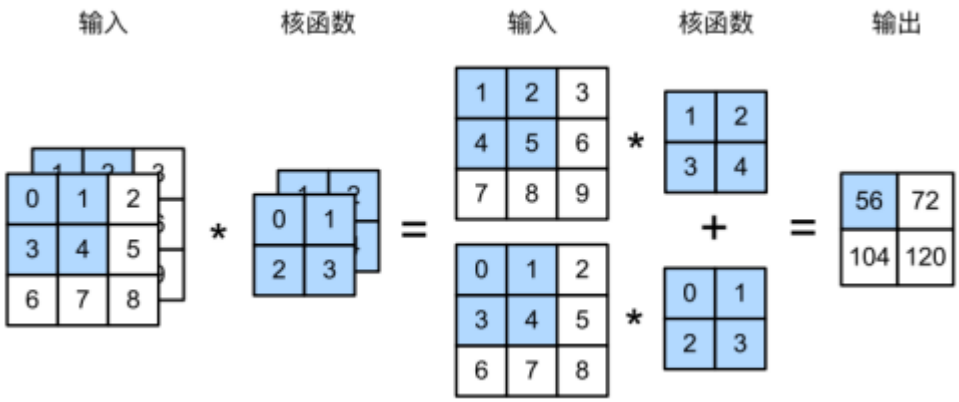

2. **多输入多输出**：情况比单输出要复杂一些。

假设我们有 a 层输入，b 层输出，卷积核大小 3×3

则一共有 b 个卷积核，每个卷积核有 a 层，每层 3×3

也就是说，输出的层数和卷积核的数量一致，输入的层数和单个卷积核的层数一致。

计算过程：对于第一个卷积核（a 层 3×3），退化为多输入单输出，计算得到一个单层输出

第二个卷积核……第三个……直到第 b 个都算完，一共得到 b 个单层输出，组成了 b 层输出

直观理解：就是上面那张图，每个核函数都按照上面处理，得到多个单层输出组成多层输出

3. 1×1 **卷积**：不负责识别邻域特征，只负责调整通道数，混合通道信息

如下图所示，如果想将 a 层输入转化为 b 层输出，只需要 b 个卷积核，每个卷积核 a 层，处理后就会得到和输入同样大小的输出，只不过层数改变了。

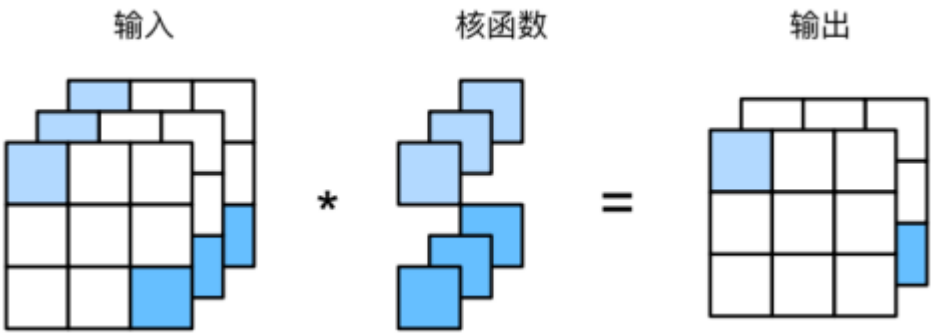

（输入 3 层，核函数 3 层，2 个，输出 2 层）

换一种视角，当以每像素为基础应用时，1×1 卷积层相当于全连接层。

汇聚层

目标：降低卷积层对位置的敏感性，同时降低对空间降采样表示的敏感性。

具体实现：和卷积核在输入上移动类似，只不过现在的卷积核不再学参数，而是像多层感知机中的隐藏层一样，对于输入做特定的运算得到输出

1. **最大汇聚层**：输出=输入范围内最大值

用途：关注"这块区域有无某个特征相应，具体有多强"

2. **平均汇聚层**：输出=输入范围内的均值

用途：关注"这一块区域整体平均有多强"

好处：

1. 降低空间分辨率，减小计算量
2. 提高对小位移的鲁棒性（同样特征稍微移动，只要还在汇聚层卷积核的扫描范围内就不会丢失）
3. 最大汇聚->突出主要特征

如果是多通道，汇聚层**不会改变通道个数。**本质上来讲，汇聚层只是单独处理了各个通道的数据，通道之间不关联。

总结：汇聚层主要不是发明新特征，而是对已有特征做压缩和总结。

卷积神经网络（以 LeNet 为例）

LeNet 是最早发布的卷积神经网络之一，目的是识别图像中的手写数字。

其结构如下图所示

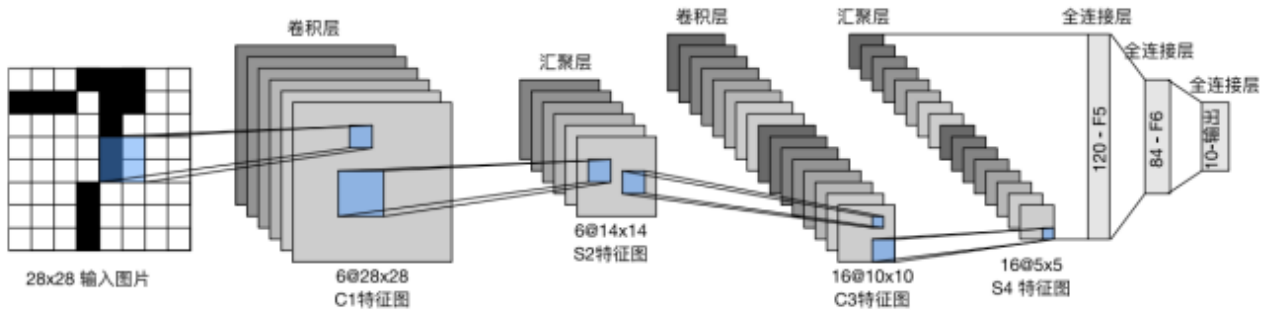

也就是

$$\text{输入} \to \text{卷积} \to \text{汇聚} \to \text{卷积} \to \text{汇聚} \to \text{全连接} \to \text{全连接/输出}$$

特征：前半部分：经过两次卷积，汇聚，通道数越来越多，而每个通道中的元素个数变少（空间尺度变小）。这也是大多数神经网络的特征。

因为**空间尺度变小**->减小计算量，同时让一个元素对应的感受野扩大

通道数变多->通道数可以理解为**特征种类**，可以表示的特征种类越多、越抽象

后半部分：通道足够多，每个通道元素足够少，就可以直接进入全连接层，进行学习并分类。

总结：

- 卷积神经网络（CNN）是一类使用卷积层的网络。
- 在卷积神经网络中，我们组合使用卷积层、非线性激活函数和汇聚层。
- 为了构造高性能的卷积神经网络，我们通常对卷积层进行排列，逐渐降低其表示的空间分辨率，同时增加通道数。
- 在传统的卷积神经网络中，卷积块编码得到的表征在输出之前需要由一个或多个全连接层进行处理。