多层感知机（第一部分）

1. 隐藏层

隐藏层是在输入层与输出层之间插入的一层，用于执行非线性运算。

1.1 为什么需要隐藏层?

现实中的输入与输出关系往往不是线性的。若只依赖线性回归层的叠加，则多层线性关系在数学上可以等效为一层线性关系，因此模型表达能力有限。换句话说，现实中的输入输出关系通常很复杂，而单纯的线性模型复杂度不够。隐藏层为模型赋予了“非线性变换”的能力，使其能够更好地表征复杂关系。

1.2 结构示意

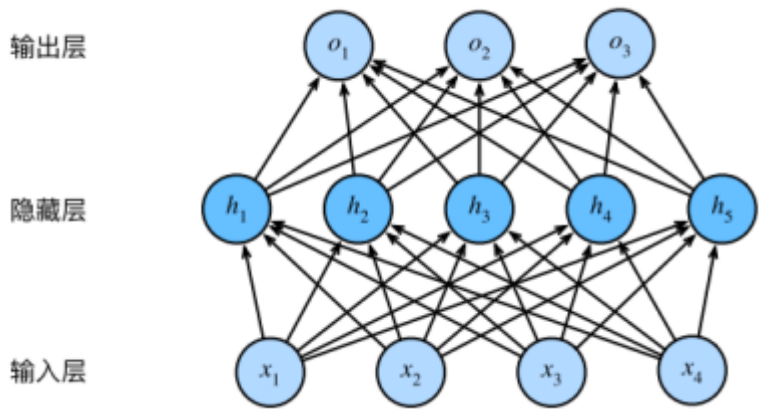

图 1 展示了一个单隐藏层的全连接多层感知机：输入层包含 x_1到x_4，隐藏层包含h_1 到 h_5，输出层包含 o_1到 o_3，相邻层之间采用全连接方式。

2. 激活函数

激活函数 σ用于描述隐藏层对输入数据的非线性处理。

例如，原先的线性回归方程可写为：

$$O = WX + b$$

加入隐藏层后，可写为：

$$H = WX + b$$

$$O = \sigma(H) = \sigma(WX + b)$$

2.1 `ReLU` 函数

`ReLU` 会将负数截断为 `0`：

$$\mathrm{ReLU}(x) = \max(x, 0)$$

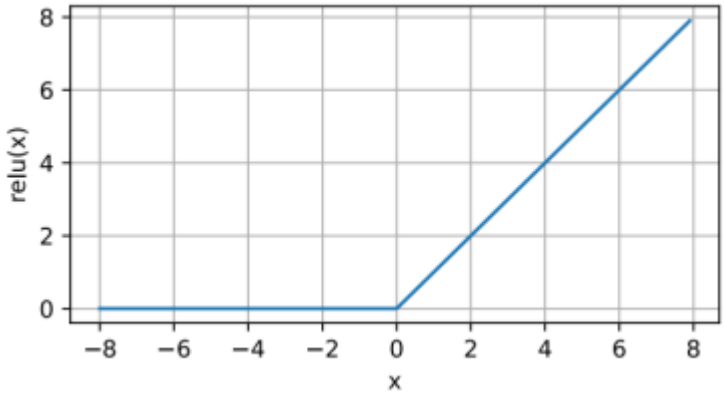

图 2 表明：当 `x < 0` 时，`ReLU(x) = 0`；当 `x \ge 0` 时，`ReLU(x)` 随 `x` 线性增长。

2.2 `sigmoid` 函数

`sigmoid` 通过负指数变换将实数轴压缩到区间 `(0, 1)`：

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

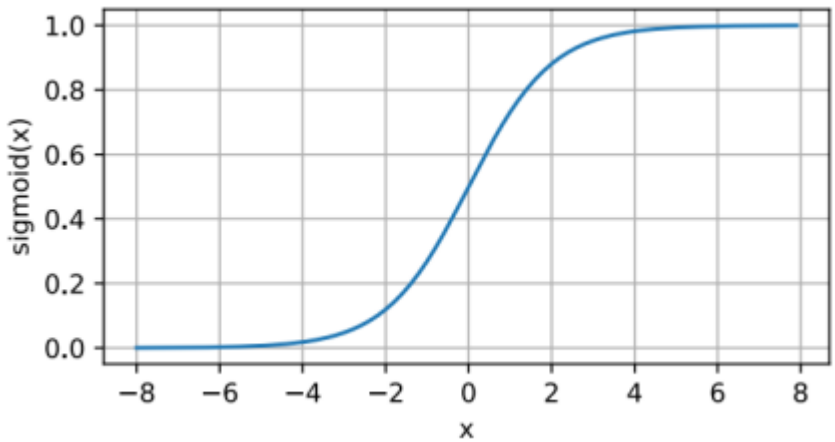

图 3 表明：`sigmoid` 曲线单调递增，并在两端逐渐饱和到 `0` 和 `1`。

2.3 `tanh` 函数

`tanh` 将实数轴压缩到区间 `(-1, 1)`：

$$\tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

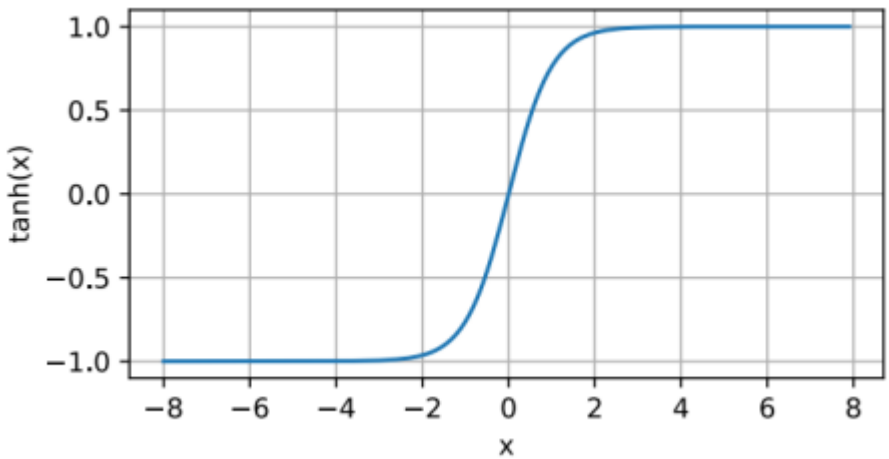

图 4 表明：`tanh` 曲线单调递增，并在两端逐渐饱和到 `-1` 和 `1`。

3. 模型选择、欠拟合与过拟合

3.1 基本概念

- 训练误差：模型在训练集上的误差。
- 泛化误差：模型在同分布的无限样本上预测误差的期望。
- 欠拟合：模型训练得不够充分，通常存在一个更复杂的模型能够做得更好。
- 过拟合：训练误差很小，但泛化误差反而很大。

3.2 影响模型拟合程度的两个因素

3.2.1 模型复杂度

一般来说，随着模型从简单变得复杂，训练误差会持续下降，但泛化误差通常会先下降后上升。

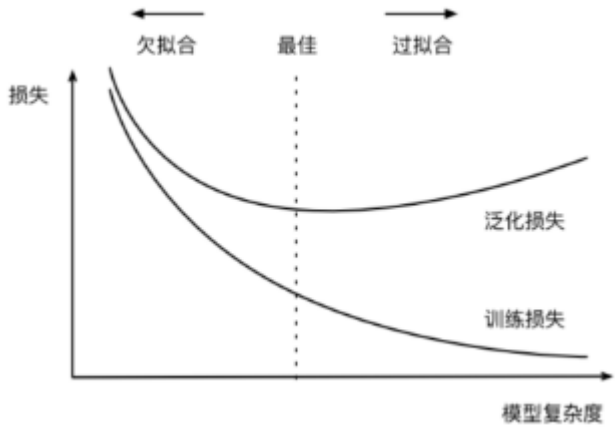

图 5 说明：当泛化误差开始增大时，说明模型已经过于复杂，出现了过拟合现象。

3.2.2 数据集大小

训练样本通常越多越好。训练样本越少，越容易出现严重的过拟合现象。一个直观例子是：若要拟合一条抛物线，却只给出两个点，那么拟合出来的直线可以使训练损失为 `0`，但泛化误差会很大。

3.3 多项式回归示例

考虑拟合一个带噪声的三阶多项式：

$$y = 5 + 1.2x - 3.4\frac{x^2}{2!} + 5.6\frac{x^3}{3!} + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, 0.1^2)$$

- 当模型过于简单时（例如线性模型），显然无法很好地拟合数据。
- 当模型过于复杂时（例如用 `10` 阶多项式拟合），模型会轻易受到训练数据中噪声的影响，导致曲线呈现反常而陡峭的上下波动。
- 极限情况下，若数据集中给出 `k` 个点，则总可以构造一个 `k` 阶多项式完美穿过这 `k` 个点，使训练损失为 `0`；但此时曲线可能完全失去原三阶多项式的形状特征，泛化误差会非常大。

4. 如何避免或降低过拟合？

核心思想是正则化，即在模型训练时引入额外约束，降低模型复杂度，从而减轻过拟合并提高泛化能力。

4.1 权重衰减

权重衰减也称 L_2 正则化。其思想是：既然过拟合通常由模型过于复杂引起，那么就可以在训练时对模型施加约束，使其不要变得过于复杂。为了学习训练集中由噪声引起的过分精细的细节，复杂模型往往会倾向于把某些权重拉得很大。

因此，可以在损失函数中加入一个与权重相关的惩罚项；当权重过大时，这个惩罚项也会变大。

原始损失函数记为：

$$L(w, b)$$

加入权重衰减后，损失函数变为：

$$L(w, b) + \frac{\lambda}{2}\|w\|^2$$

其中，λ为正则化常数，也是一个超参数，在训练过程中不改变。这样可以使 `w` 维持在相对较小的范围内，从而避免过度过拟合。

4.2 暂退法（`dropout`）

`dropout` 的核心思想是提升模型的鲁棒性。一个好的模型应该是稳健的，即使在计算过程中加入一些扰动，也不会对结果造成过大影响。

在实际训练中，某些神经元可能会对某些固定模式形成强依赖，从而导致过拟合。为了破坏这种“共适应性”，可以在训练时随机打断这些固定搭配，让模型中的每个神经元更加独立，使模型不会过分依赖某条局部通路，并对输入扰动更鲁棒。

在训练时（注意：测试时不使用），对于隐藏层中的每个值 `h`，进行如下变换：

$$h' = \begin{cases} 0, & \text{with probability } p, \\ \frac{h}{1-p}, & \text{otherwise.} \end{cases}$$

这意味着：隐藏层中的每个节点都会以 p 的概率被直接置为 `0`；其余节点则被缩放为 $\frac{h}{1-p}$，以保证期望不变。

在模型结构上，被置为 `0` 的节点在该次训练的前向传播中不参与计算，在反向传播中也不会产生影响。

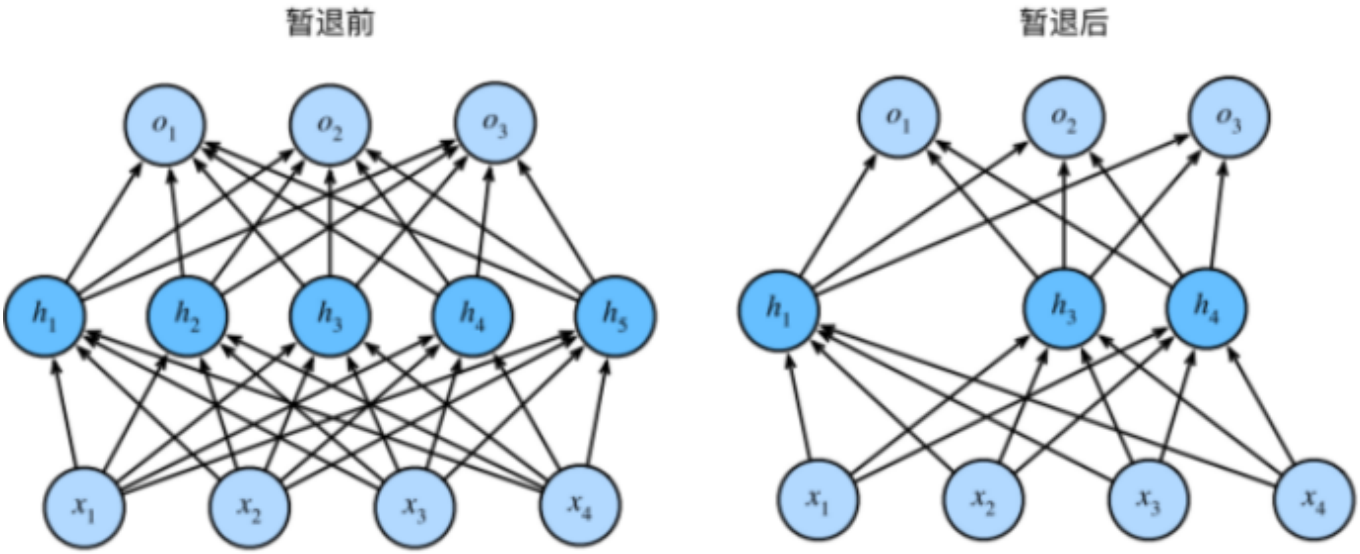

图 6 展示了 `dropout` 前后多层感知机结构的对比：`dropout` 后，部分隐藏层节点及其相关连接会临时“消失”。