线性神经网络：线性回归与 Softmax 回归

线性回归

输入输出： 一个输入 $\mathbf{X}$，是一个 tensor；一个输出 y，是标量。

参数： "斜率" $\mathbf{w}$，也是一个 tensor；偏置 b，是标量。

线性模型：

$$\hat{y} = \mathbf{w}^\top \mathbf{x} + b$$

线性回归主要用于单个值的预测：给定一个输入，经过计算得到输出，这个输出就是预测值。

典型应用： 房价预测——在不同的面积、房屋高度（输入）等条件下预测房价（输出）。

定义损失函数

$$L(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^{n} l^{(i)}(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^{n} \frac{1}{2} \left(\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)} \right)^2$$

理解： 在参数 $\mathbf{w}, b$ 的条件下，在给定的 n 个数据的数据集上，$\frac{1}{2}(\text{预测值} - \text{真实值})^2$ 求和然后平均到 n 份上，就是当前模型在这 n 个样本上的平均损失。

目标： 找到一组 $(\mathbf{w}, b)$，使得在所有训练样本上最小化损失。

实现目标的方法：小批量随机梯度下降

具体操作：

1. 每次，从数据集中随机抽取一个小批量 $\mathcal{B}$（由固定数量的训练样本组成）。
2. 然后，计算当前参数、样本情况下损失对于训练参数 $(\mathbf{w}, b)$ 的偏导数（也就是梯度）。（具体计算方法和规则见上一篇笔记。）
3. 最后，将梯度乘以学习率 η（一个预先决定的正数），从原来的参数中减去，得到新的参数。

两种参数

- **超参数：** 手动指定，在学习过程中不更改。例如这里的小批量数据个数 $|\mathcal{B}|$ 以及学习率 η。
- **模型参数：** 需要在学习中自动求梯度修正。例如这里的 $\mathbf{w}$ 和 b。

用模型进行预测

根据训练好的 $\mathbf{w}$ 和 b，输入数据，得到预测的输出数据。

损失函数为什么定义成残差的平方？

由数学推导可得，当观测中包含服从正态分布的噪声时，最小化均方误差（在当前损失函数定义下即为最小化损失）等价于对线性模型的极大似然估计，此时取到的参数 $\mathbf{w}$ 和 b 是最优值。

神经网络

如下图所示，可以将线性回归模型描述为一个神经网络。该神经网络的层数为 1。同时，对于每个输入都与每个输出相连的层，称为**全连接层**（稠密层）。

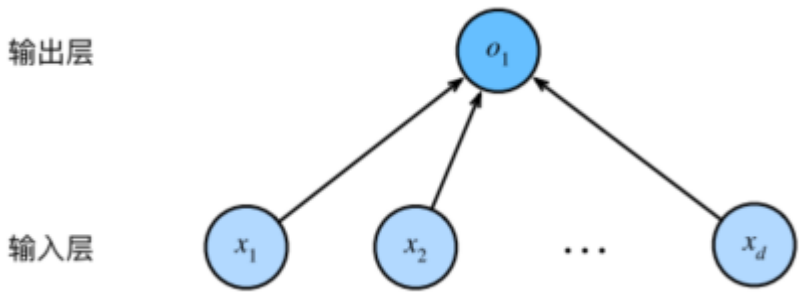

> **图 1：** 线性回归的单层神经网络——输入层有 $x_1, x_2, \ldots, x_d$ 共 d 个节点，输出层有 o_1 一个节点，每个输入与输出之间均有连接。

Softmax 回归

与线性回归不同之处在于，输出和偏置现在也变成了 tensor 而非标量。

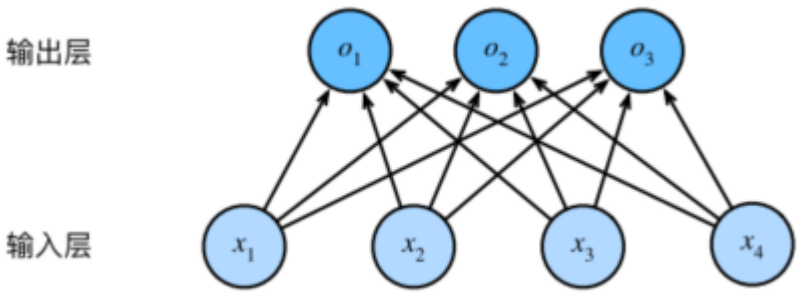

> **图 2：** Softmax 回归的单层神经网络——输入层有 x_1, x_2, x_3, x_4 共 4 个节点，输出层有 o_1, o_2, o_3 共 3 个节点，每个输入与每个输出之间均有连接（全连接层）。

Softmax 回归模型为：

$$\mathbf{o} = \mathbf{W}\mathbf{x} + \mathbf{b}$$

其中所有量均为 tensor。

Softmax 主要用于**分类**：给定一个输入，经过计算得到输出，从输出各个数据之间表征"这个输入最有可能落在哪一类"。

典型应用： 手写数字识别——这个数字最有可能是 0–9 中的哪一个？

问题与解决

问题： 得到的输出 o_i 不一定都是正数、不一定和为 1，不能直接当成概率。

解决： softmax 函数归一化：

$$\hat{\mathbf{y}} = \mathrm{softmax}(\mathbf{o}), \quad \text{其中} \quad \hat{y}_j = \frac{\exp(o_j)}{\sum_k \exp(o_k)}$$

损失函数：交叉熵损失

$$l(\mathbf{y}, \hat{\mathbf{y}}) = -\sum_{j=1}^{q} y_j \log \hat{y}_j$$

其中，y_i 为"该输入实际分类为第 i 类的概率"，$\hat{y}_i$ 为"模型预测该输入为第 i 类的概率"。

注意： 虽然形式是求和，但是 y_i 实际上只在正确的那一类取 1，其他都取 0。所以，实际上损失函数为：

$$l = -\log \hat{y}_c$$

其中 c 为正确类别的索引。

换句话讲，损失只关心"正确"的那一项预测的概率和 1 差多远，差得越远损失越大。

训练

参数更新过程和线性回归基本相同。