

# 计算机视觉

---

计算机视觉的任务：让计算机像人眼一样“看懂”图像。

具体应用：图像分类、目标检测、语义分割、实例分割、风格迁移.....

## 从宏观到微观

---

1. **图像分类**：这张图里有什么？
2. **目标检测**：有什么？ 分别在哪里？
3. **语义分割**：每一个像素是什么类别？
4. **实例分割**：每一个像素属于哪一个具体物体？

## 改进泛化的两种手段

---

### 图像增广

---

通过对**训练图像**做**随机变化**（翻转、裁剪、调整亮度/对比度/饱和度/色调、组合增广）来**扩大训练集规模**、**降低模型对位置和颜色等的依赖**，从而**减轻过拟合**，提升在测试集上的表现。

**注意：** 增广只针对训练集，不针对测试集。

直观理解：

- **训练阶段**：老师把同一道题换不同说法，让学生真正理解；
- **考试阶段**：题目应该固定，才能稳定评价学生。


### 微调

---

问题：想训练一个模型，但是**样本有限**，手里的数据集规模太小，**容易产生过拟合**。

解决方法：**从一个不错的模型出发微调**，来达到我们需要的目的。

示意图如下：



【图片：迁移学习示意图——源模型的输出层随机初始化，底层参数复制到目标模型，再进行训练或微调】

左侧是一个通用的、经过充分预训练的源模型，右侧是我们想要训练的模型。

首先，**保留源模型所有的层**，只将最后的**输出层**换成符合当前任务的形式。

（例如，源模型是一个 1000 类的分类器，现在我们想训练一个判断热狗模型，则换成一个 2 类（是或否）的分类器。）

然后，在**目标训练集上**（这里是一堆热狗和非热狗的图片）**继续训练**。

**注意：**继续训练时，**新加的输出层**因为还没有任何有效信息，需要**高学习率**；而保留的**剩余各层**已经得到充分训练，**学习率应当较低**。

直观理解：老员工熟悉各种业务，迁移到新业务上只需要稍微改一点；新员工什么都不会，需要大幅度改动，进行更强的训练。

特例：冻结特征层，即除了输出层以外的其它层都不变（学习率为 0）。

### 1. 为什么可以这么做？实际上，一个神经网络越深的层学到的东西越和原始任务相关（也就是**丢失泛用性，提高特化性**）。

直观理解：浅层学到了边缘、线条、纹理等特征，可以泛用于多种任务；最深层，也就是最后的分类层，只看“是不是热狗”，完全针对当前任务，几乎没有泛化性。

所以在迁移（改变模型的任务）时，**对浅层取较低的学习率，对深层取较高的学习率**。

# 目标检测

目标检测把单一物体的“这张图是什么”扩展为**多个物体**的“**这张图有哪些东西，分别在哪**”。

界定某个物体“在哪”，可以采用**边界框**：用**横平竖直的矩形框**框住该物体。边界框有两种常见表示方式：

- 左上角点坐标、右下角点坐标；
- 中心点坐标、高度、长度。

两种表示方式都由四个数字组成。

## 锚框 (anchor)

如何训练一个模型，给一张图，识别出“这张图有哪些东西，分别在哪”？

使用**锚框**：以图片的每一个像素为**中心点（注意后面这里会变）**，生成**长宽比不同、大小不同**的框。

## 训练流程

训练的输入是**人为标注好真实框以及物体的图片**。

1. **生成锚框**：这一步是机械的、写死的，和模型、图片都无关。
2. **计算每个锚框与真实框的 IoU**，根据设定好的阈值为锚框进行**分类**。

**IoU** 衡量两个框的重合程度：

$$\text{IoU} = \frac{\text{两框交集面积}}{\text{两框并集面积}} \in [0, 1]$$

**IoU 越大，两个框越匹配。**

这里的按阈值分类是简化的说法。实际上，会为每个真实框匹配至少一个锚框，避免出现所有锚框 IoU 都低于阈值、导致没有正锚框的情况。

3. 根据 IoU 对锚框分成两类：

- **正锚框**：IoU 值较高，与真实框重合度高。得到**类别标签**（该真实框的物体类别），并计算该锚框和真实框的**中心偏移量、长宽差距量**，得到**偏移标签**。两个标签组合起来，得到该正锚框的**监督标签**。
- **负锚框**：IoU 值较低，与真实框重合度低。类别标签为背景；负锚框的监督标签即类别标签，没有偏移标签。

**监督标签**：训练时用来告诉模型“正确答案是什么”的数据。

- 回到一开始生成的锚框，**模型根据学习到的参数以及图像信息**（如何根据图像信息，见下一节）**预测每个锚框的情况**：类别是什么？偏移量是多少？然后和监督标签作比较，产生的差异即为损失。
- 通过**反向传播优化模型参数**，降低损失，提高预测准确度，达成训练的目的。

## 预测流程

预测的输入是**纯图片**，没有人为标注的真实框。

- 还是生成锚框。这一步是机械的、写死的，和模型、图片都无关。
- 直接跳转到训练流程的第 4 步：**模型根据学习到的参数以及图像信息预测每个锚框的情况**。  
对于每个锚框，模型产生其对应不同类别的权重，通过 `softmax` 映射到概率上。预测该锚框的类别即为概率最大值对应的类别，该值即为**置信度**。同时预测偏移量。
- 去掉预测为背景的锚框，保留预测为物体的锚框。这些**锚框经过各自预测的偏移量修正后，得到预测框**。
- NMS 去重**：对于同一物体，有**多个预测框的类别均为该物体**时：
  - 按照**置信度从大到小**排序，选出其中**置信度最大的预测框 A 并保留**；
  - 计算剩下的**预测框与 A 的 IoU**；
  - 根据事先确定好的阈值，筛选出**低于阈值的预测框**并保留下来。

如果保留了多个预测框，则认为图中存在**多个同一类型物体的不同实例**。注意，这里**不是合并**。

## 多尺度目标检测

上面的锚框有一个很大的问题：**数据量太大**。


如果在  $100 \times 100$  像素的图片上，每个像素点生成 4 个锚框，一共有 40000 个锚框。真实任务中图像的大小比  $100 \times 100$  还要大，锚框的数量太多了。

解决方法是使用**多尺度目标检测**：


- 较大的特征图 + 较小的锚框 → 检测小物体；
- 较小的特征图 + 较大的锚框 → 检测大物体。

**特征图**：原图经过 **CNN** 后得到的、通道数更多而大小更小的数据，具体参考卷积神经网络的笔记。

举个例子：如果要检测的物体较小，原图经过卷积池化后得到  $4 \times 4$  的特征图，则在原图中以这  $4 \times 4$  个点对应的像素点为中心生成锚框，锚框的大小设定较小；反之，如果要检测的物体几乎填满整个图片，则可以选择  $1 \times 1$  的特征图，对应到原图中心取 1 个像素作为生成锚框的中心点。如下图所示，左图是  $4 \times 4$  的例子，右图是  $1 \times 1$  的例子。



【图片：多尺度锚框示意图 —— 较大特征图上生成较小锚框】



【图片：多尺度锚框示意图 —— 较小特征图上生成较大锚框】

这一步其实只是单纯地改编了取锚框的中心点以及大小，和特征图对应是为了方便后续训练和预测。

现在来解答上一节的疑问：模型如何**结合图片信息**以及已经学到的参数来预测？

答案：**图片信息 = 特征图对应位置的各个通道的数据。**

这一节是上一节锚框的补充，只是**优化了锚框的选取**，降低计算量，同时明确了模型如何读取图片信息来预测。需要注意的是，模型**在预测时并不知道目标的大小有多大**，所以采用**多套尺度同时运行**并计算，得到的不同尺度信息之间相互竞争，**采用置信度最高的结果**。

一个完整的流程：输入图片 → **同时生成多尺度特征图** → 所有尺度的锚框同时预测 → 各自输出类别置信度和偏移量 → 过滤低置信度框 → NMS 去除重复框 → 留下最匹配的框。

多尺度目标检测修正后的上一节锚框里的整个流程，即为**单发多框检测 SSD**。

## 区域卷积神经网络（R-CNN）系列

---

思想：前面的 SSD 在产生锚框时**没有利用图片的特征信息**，而是只根据人为设定的参数机械生成锚框，这不太好。

改进：与其让后面的分类器仔细检查成千上万个位置，不如**先做一次粗筛**，找出大约几百或几千个“这里可能有物体”的区域，称作“**提议区域**”（proposal）。

### 最原始的 R-CNN

---

利用**选择性搜索（selective search**，没有参数，不能学习，只是一个单纯的**算法**），从海量的可行矩形框中选择 2000 个“提议区域”，然后**对得到的每个提议区域分别进行 CNN**。

（其实就是把 SSD 的第一步锚框生成变成用算法粗筛出 2000 个提议区域；此外，整图 CNN 变成每个区域分别 CNN，其他的都一样。）

**注意：**“初筛”指的是从海量可行矩形中用算法筛出 2000 个提议区域，而不是根据 2000 个提议区域再去筛选更少的区域。

弊端：太慢了，2000 个区域要算 2000 遍 CNN。

### Fast R-CNN

---

改进：把“每个 proposal 分别 CNN”变成“**全图 CNN**，每个 proposal 根据位置截取特征图中**自己对应部分**”作为自己的特征。

举例：原图是  $100 \times 100$ ，压缩到的特征图是  $10 \times 10$ 。记 proposal 为  $(x_1, y_1, x_2, y_2)$ 。

此时，一个在原图中 (10, 20, 30, 40) 的 proposal 映射到特征图中，则取 (1, 2, 3, 4)。

产生新问题：每个 proposal 大小不同，截取的**特征区域大小也不同**，不便于后续输入全连接层处理（全连接层需要固定长度输入）。

解决：使用 **RoI (region of interest) Pooling**，对截取到的 proposal 特征区域进行“**标准化**”，变成同样的规格。

具体操作：假设需要标准化为  $3 \times 3$ ：

- 如果区域大于  $3 \times 3$ ，则将其划分为  $3 \times 3 = 9$  大块，每一大块内部进行 max pooling（取最大值池化）；
- 如果区域小于  $3 \times 3$ ，则复制扩展；极端情况  $1 \times 1$  时，就扩展成  $3 \times 3 = 9$  个一样的数字。

（总而言之，就是**标准化处理**。）

弊端：产生 proposal 的机制还是传统算法 selective search，**不够聪明，而且速度也慢**。

## Faster R-CNN

---

改进：**把 selective search 换成一个神经网络 RPN**（region proposal network，区域提议网络）。

RPN 的任务：**看 CNN 特征图，自己学习哪些区域可能存在物体**。

RPN 其实就是简化版本的 SSD，只不过预测的类别由多种降低到两种：“有”或者“无”。

Faster R-CNN 的流程：先生成锚框（生成方法和前面一样），再用 RPN 将锚框筛选、微调等成为 proposal，剩下的流程和 Fast R-CNN 相同。

## Mask R-CNN

---

在 Faster R-CNN 的基础上实现**实例分割**。

例如，Faster R-CNN 找到了几个含有猫的矩形框，则 Mask R-CNN 进一步分析：**这几个矩形框里哪些像素真正属于这只猫**。

由于像素级预测精度要求高于矩形框，将之前采用的 RoI Pooling **优化为更精细的 RoIAlign**。

直观理解：Faster R-CNN 负责“找到目标并画框”，Mask R-CNN 在此基础上继续“给每个目标抠图”。




# 转置卷积

为什么需要？在**像素级预测**（语义分割、实例分割）的任务中，需要对原图中的**每个像素都进行分类**。但是缩小后的特征图大小远小于原图，无法实现针对特定像素的预测。所以需要转置卷积：**将缩小的特征图恢复到原图的大小**，同时保留部分特征结构。

两个名词：

- **下采样**：将特征图缩小的过程，特征图的分辨率变低；
- **上采样**：反之。

计算过程：矩阵的数乘 + 移位叠加，具体例子见下图。



【图片：转置卷积计算过程 —— 输入矩阵经过转置卷积与移位叠加后得到输出】

转置卷积是**可学习的**：可学习参数包括**核矩阵的权重**（每个空里的数）以及**偏置**（最后的结果每个空统一加上一个常数）。


**注意：** 转置卷积可以扩大特征图尺寸，却不能凭空恢复普通卷积丢失的全部信息。

# 全卷积网络（FCN）

利用转置卷积实现语义分割（像素级别分类）。

简明实现流程如下图所示：





【图片：FCN 流程图——输入图像经过卷积神经网络、 $1 \times 1$  卷积层和转置卷积层，输出每个像素的类别】

首先，原图（例如  $3 \times 512 \times 512$ ）经过卷积神经网络转换为特征图（例如  $50 \times 32 \times 32$ ），然后经过  $1 \times 1$  卷积层。

（回顾一下  $1 \times 1$  卷积层：只对每个位置的不同通道数据进行整合处理，**不改变特征图的大小，只改变特征图的通道数。**）

将原特征图的**通道数**改为**需要识别的种类数**（例如这里一共有三种：狗、猫、背景），则为  $3 \times 32 \times 32$ 。

然后，经过**转置卷积**将**小特征图**扩大到和原图大小相同。这一步**不改变特征图的通道数**，得到  $3 \times 512 \times 512$ 。

注意：转置卷积其实可以改变特征图的通道数，这里没有改变是为了将**功能职责分开**：  
 $1 \times 1$  卷积层负责修正通道数，转置卷积层负责扩大图像大小。

最后，根据特征图**每个像素处的各个不同通道对应的值**进行 `softmax` 处理，概率最高的就认为是某一分类。

(这里和整个图像的分类识别几乎一样，就是看不同通道谁的权重高就选谁。)

也就是说：**卷积网络负责提取语义特征**， $1 \times 1$  **卷积负责产生类别通道**，**转置卷积负责恢复空间分辨率**。

**可学习参数**：卷积神经网络、 $1 \times 1$  卷积层、转置卷积层均可进行学习。

**训练方法**：训练图像的每个像素都打标签；对于每个像素，预测和实际之间的交叉熵损失即为 `loss`，通过反向传播更新卷积层和转置卷积层的参数。